

LAPORAN EKSPERIMEN

FINE-TUNING LARGE LANGUAGE MODEL

BERBASIS LORA UNTUK BAHASA DAERAH INDONESIA

Menggunakan Model Qwen2.5-0.5B dan Dataset Cendol

I. DASAR TEORETIS PRE-TRAINING DAN KETERBATASAN INSTRUKSI

1.1 Fungsi Loss pada Proses Pre-Training

Selama tahap pre-training, model Qwen2.5-0.5B dioptimalkan menggunakan fungsi Causal Language Modeling Loss (CLM Loss) yang secara matematis dirumuskan sebagai berikut.

$$L_{\text{CLM}} = - (1/N) \times \text{jumlah} \log P(t_i | t_1, t_2, \dots, t_{i-1}; \theta)$$

Di dalam formula tersebut, t_i merupakan token ke- i dalam urutan teks, θ adalah seluruh parameter model yang berjumlah 494 juta bobot, dan N adalah panjang urutan. Dengan demikian, model dioptimalkan untuk memaksimalkan probabilitas token berikutnya di setiap posisi, dengan data pelatihan berupa triliunan token teks yang tidak memiliki format instruksi-jawaban.

1.2 Distribusi Data Corpus Pre-Training

Karena fungsi L_{CLM} dihitung secara merata di seluruh posisi token tanpa diskriminasi, model belajar memodelkan distribusi statistik teks internet secara keseluruhan, bukan distribusi khusus teks tanya-jawab. Corpus internet didominasi oleh artikel berita, halaman ensiklopedia, forum diskusi, dan komentar, sedangkan percakapan instruksi-jawaban hanya menempati proporsi yang sangat kecil.

Akibatnya, ketika model menerima kalimat tanya seperti "Apa makna filosofi Jawa Memayu Hayuning Bawana?", mekanisme gradient descent mendorong model untuk memprediksi token berikutnya yang paling umum muncul setelah kalimat tanya di internet, yaitu header artikel atau navigasi situs web, bukan jawaban substantif.

Hal ini dibuktikan oleh hasil eksperimen berikut:

Instruksi: Apa makna filosofi Jawa 'Memayu Hayuning Bawana'?

Respons base model: Pusat Pendidikan dan Pembelajaran | Home >> Pemahaman
>> ...

Model menghasilkan format navigasi situs web karena itulah pola statistik yang paling sering muncul setelah kalimat tanya dalam corpus pelatihan.

1.3 Perbedaan Fundamental antara Objective Pre-Training dan Inferensi

Persoalan mendasar yang terjadi adalah bahwa fungsi L_CLM bersifat format-agnostic, artinya fungsi tersebut tidak membedakan apakah model sedang menjawab pertanyaan atau sekadar melanjutkan suatu artikel. Yang menjadi acuan utama hanyalah probabilitas token berikutnya yang tinggi.

Aspek	L_CLM (Pre-Training)	L_SFT (yang Diinginkan)
Input	Sembarang teks	Instruksi manusia
Target	Token berikutnya	Respons yang tepat
Supervision	Self-supervised	Supervised
Sinyal	Statistik corpus	Niat manusia
Format	Bebas	Instruksi ke Jawaban

Tabel 1. Perbandingan Objective Pre-Training dan SFT

Dengan demikian, base model memiliki pengetahuan yang luas karena L_CLM dioptimalkan terhadap miliaran token dari seluruh domain pengetahuan manusia. Namun, model tersebut lemah dalam mengikuti instruksi karena tidak pernah ada sinyal gradient yang mengajarkan model untuk beralih dari mode pelanjut teks menjadi penjawab instruksi. Supervised Fine-Tuning (SFT) memperbaiki kondisi ini dengan mengubah distribusi pelatihan menjadi pasangan instruksi-respons dan menerapkan loss masking sehingga gradient hanya mengalir dari token respons.

II. EFISIENSI PARAMETER LORA DALAM PROSES FINE-TUNING

2.1 Proporsi Parameter yang Dilatih

Berdasarkan data aktual eksperimen yang tercatat pada Cell 6, konfigurasi LoRA yang diterapkan menghasilkan statistik parameter sebagai berikut: arsitektur

Qwen2ForCausalLM dengan target modul mencakup q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, dan down_proj. Dari total 498.431.872 parameter model, hanya 4.399.104 parameter yang dilatih, setara dengan 0,88 persen dari keseluruhan parameter. Sebanyak 494.032.768 parameter atau 99,12 persen dalam kondisi beku (frozen). Ukuran adapter yang dihasilkan adalah 33,5 MB.

Hasil tersebut menunjukkan bahwa hanya 0,88 persen parameter yang dilatih selama proses fine-tuning berlangsung.

2.2 Mekanisme Matematis LoRA

LoRA menambahkan dua matriks kecil pada setiap lapisan yang ditarget, yaitu $\Delta W = B \times A$, di mana A merupakan matriks down-projection berukuran r kali k dan B merupakan matriks up-projection berukuran d kali r. Rank yang digunakan adalah $r = 8$ sebagai hyperparameter. Untuk Qwen2.5-0.5B, setiap lapisan atensi memiliki dimensi $d = 896$.

Modul	Dimensi	Parameter per Layer	Jumlah Layer
q_proj	896 x 896	14.336	24
k_proj	896 x 128	14.336	24
v_proj	896 x 128	14.336	24
o_proj	896 x 896	14.336	24
gate_proj	896 x 4864	14.336	24
up_proj	896 x 4864	14.336	24
down_proj	4864 x 896	77.824	24

Tabel 2. Rincian Parameter LoRA per Modul

2.3 Dampak terhadap Efisiensi

Terdapat lima dimensi efisiensi yang dihasilkan dari penerapan LoRA dalam eksperimen ini. Pertama, efisiensi penyimpanan: base model Qwen2.5-0.5B berukuran 988 MB, sedangkan adapter LoRA hanya 33,5 MB, sehingga menghemat 96,6 persen ruang penyimpanan. Kondisi ini memungkinkan satu server menyimpan 29 adapter LoRA berbeda dalam ruang yang setara dengan satu model full fine-tuned.

Kedua, efisiensi komputasi pelatihan: karena 99,12 persen parameter dalam kondisi beku, gradient hanya dihitung untuk 4,4 juta parameter. Total waktu pelatihan tercatat 575,8 detik atau sekitar 9,6 menit untuk 1.295 contoh selama 2 epoch.

Ketiga, efisiensi memori GPU: dengan `gradient_checkpointing` aktif, eksperimen berjalan tanpa kesalahan kehabisan memori pada GPU T4 15,6 GB. Keempat, efisiensi pengetahuan: karena bobot base model tidak berubah, seluruh pengetahuan yang diperoleh selama pre-training tetap utuh sehingga mencegah catastrophic forgetting. Kelima, efisiensi modularitas: satu base model dapat digunakan bersama oleh berbagai adapter yang masing-masing dilatih untuk bahasa daerah yang berbeda, suatu arsitektur yang sangat relevan mengingat Indonesia memiliki lebih dari 700 bahasa daerah.

III. ANALISIS PERBANDINGAN RESPONS SEBELUM DAN SESUDAH FINE-TUNING

3.1 Contoh Pertama: Pertanyaan Filosofi Budaya

Prompt yang digunakan adalah: "Jelaskan makna filosofi Bugis Siri Na Pacce dan relevansinya hari ini."

Base model menghasilkan respons dalam format soal pilihan ganda: "Pilihan yang paling cocok adalah...? A. filosofi yang kuat dan kuat B. karakteristik perintah, keputusan dan kekerasan..." Model tidak mencoba menjawab pertanyaan, melainkan membuat soal baru dari pertanyaan yang diberikan.

Model fine-tuned menghasilkan respons dalam format artikel berita dengan struktur jurnalistik yang mencantumkan kota, tanggal, dan narasumber. Meskipun kontennya masih tidak sepenuhnya relevan, format output telah bergeser ke arah teks informatif, bukan format soal pilihan ganda.

3.2 Contoh Kedua: Pertanyaan Perbandingan Budaya

Prompt yang digunakan adalah: "Apa perbedaan antara wayang kulit dan wayang golek?"

Base model menghasilkan respons yang keluar topik secara menyeluruh dengan mengubah pertanyaan perbandingan menjadi pertanyaan baru tentang "pengecut dalam film Wayang Kulit" dan kemudian menjawab pertanyaannya

sendiri. Ini menunjukkan dua kegagalan sekaligus, yaitu gagal memahami format instruksi dan menghasilkan konten yang tidak berkaitan.

Model fine-tuned menghasilkan format pilihan ganda, namun konten pilihan-pilihannya relevan dan membahas wayang kulit serta wayang golek secara langsung. Terdapat pergeseran dari respons yang sama sekali keluar topik menjadi respons dengan konten relevan, meskipun format masih belum optimal.

3.3 Contoh Ketiga: Instruksi Kuliner

Prompt yang digunakan adalah: "Bagaimana cara membuat opor ayam? Sebutkan bahan dan langkahnya."

Base model menghasilkan format yang benar berupa daftar bahan karena resep makanan merupakan konten yang sangat umum dalam corpus internet. Namun kontennya sepenuhnya salah dengan bahan-bahan yang tidak relevan seperti tepung tapioka dan kecap manis, bukan bahan opor ayam seperti santan, ayam, kunyit, dan serai.

Model fine-tuned menunjukkan upaya yang lebih sesuai konteks dalam menyusun respons berdasarkan contoh instruksi kuliner dalam data pelatihan.

3.4 Rangkuman Perbandingan

Dimensi	Base Model	Model Fine-Tuned
Format output	Acak: soal ujian, artikel tidak relevan	Lebih konsisten: artikel, deskripsi semi-terstruktur
Relevansi topik	Sangat rendah, sering keluar konteks	Sedang, lebih dekat ke topik instruksi
Akurasi faktual	Rendah	Masih rendah
Bahasa	Campuran, tidak konsisten	Lebih konsisten Bahasa Indonesia
Pola generasi	Statistik corpus mentah	Distribusi dataset pelatihan

Tabel 3. Rangkuman Perbandingan Kualitas Respons

Keterbatasan perbaikan yang dicapai disebabkan oleh tiga faktor teknis. Pertama, hanya 1.295 contoh pelatihan yang digunakan dari 12,8 juta baris yang tersedia. Kedua, pelatihan hanya berjalan selama 2 epoch dengan 324 langkah sehingga eval loss 2,7193 setara perplexity sekitar 15,2. Ketiga, dataset cendol bersifat heterogen dengan topik yang sangat beragam sehingga model tidak mendapat sinyal yang cukup untuk satu domain spesifik.

IV. RISIKO OVERFITTING PADA DATASET KECIL

4.1 Definisi dan Konteks Overfitting

Overfitting dalam konteks fine-tuning LLM terjadi ketika model terlalu menyesuaikan diri dengan data pelatihan sehingga menghafal pola spesifik alih-alih belajar generalisasi. Secara matematis, overfitting ditandai dengan L_{train} mendekati nol sementara L_{eval} meningkat. Gap yang semakin lebar antara keduanya merupakan sinyal utama terjadinya overfitting.

Eksperimen ini menggunakan 1.295 contoh pelatihan untuk model dengan 498 juta parameter, menghasilkan rasio sekitar 384.950 parameter per contoh pelatihan. Dengan penerapan LoRA yang hanya melatih 4,4 juta parameter, rasio tersebut menjadi sekitar 3.397 parameter LoRA per contoh, yang lebih masuk akal meskipun masih tergolong kecil.

4.2 Deteksi Melalui Training Curve

Berdasarkan data aktual dari Cell 8 eksperimen, training loss turun dari 14,9932 pada awal menjadi 9,4515 pada akhir pelatihan, sedangkan eval loss turun dari 2,7727 menjadi 2,7193.

Indikator	Nilai	Status	Interpretasi
Train loss trend	14,99 ke 9,45	Normal	Model belajar dari data
Eval loss trend	2,77 ke 2,72	Normal	Generalisasi membaik
Gap epoch 1	$10,43 - 2,77 = 7,66$	Perlu dipantau	Wajar karena perbedaan cara hitung loss
Gap epoch 2	$9,45 - 2,72 = 6,73$	Normal	Gap menyempit, overfitting belum terjadi
Eval loss naik?	Tidak	Aman	Tidak ada kurva berbentuk U

Tabel 4. Diagnosis Overfitting dari Training Curve

Berdasarkan data tersebut, tidak terdapat indikasi overfitting pada 2 epoch pelatihan ini. Model justru berada dalam kondisi underfitting karena eval loss 2,7193 setara perplexity sekitar 15,2.

4.3 Mekanisme Pencegahan yang Aktif dalam Eksperimen

Terdapat lima mekanisme pencegahan overfitting yang aktif dalam eksperimen ini. Pertama, LoRA dropout sebesar 0,05: pada setiap forward pass, 5 persen neuron adapter dimatikan secara acak untuk mencegah adapter bergantung terlalu kuat pada neuron spesifik. Kedua, weight decay sebesar 0,01: penalti L2 ditambahkan pada fungsi loss sehingga mendorong bobot adapter tetap kecil dan mencegah nilai yang ekstrem. Ketiga, early stopping melalui `load_best_model_at_end`: Trainer secara otomatis menyimpan checkpoint terbaik berdasarkan `eval_loss` dan memuat kembali checkpoint tersebut jika eval loss mulai meningkat.

Keempat, cosine learning rate scheduler: learning rate mengikuti kurva cosine dengan warmup sebesar 5 persen langkah pertama kemudian turun secara bertahap menuju nol, sehingga mencegah update besar yang berpotensi menyebabkan overfitting di tahap akhir pelatihan. Kelima, gradient checkpointing: selain sebagai mekanisme efisiensi VRAM, recomputing aktivasi saat backward pass secara implisit memperkenalkan variasi kecil dalam gradient yang berfungsi sebagai regularisasi ringan.

4.4 Risiko Spesifik pada Domain Bahasa Daerah

Selain risiko overfitting klasik, terdapat tiga risiko tambahan yang relevan untuk konteks eksperimen ini. Risiko pertama adalah domain collapse, yaitu model hanya mempelajari format output dari sub-domain yang paling banyak muncul dalam subset data yang diambil secara acak, sehingga bahasa daerah yang jarang muncul tidak mendapat representasi yang memadai.

Risiko kedua adalah format overfitting, yaitu model cenderung menghasilkan format pilihan ganda bahkan untuk pertanyaan terbuka karena terlalu banyak melihat soal pilihan ganda dalam subset data pelatihan. Bukti kondisi ini terlihat pada hasil evaluasi kualitatif di Bagian III. Risiko ketiga adalah linguistic drift, yaitu model mungkin mulai menggeneralisasi bahasa daerah secara tidak tepat dengan mencampurkan kosakata dari bahasa daerah yang berbeda akibat data pelatihan yang tidak distratifikasi per bahasa.

4.5 Kesimpulan Analisis Overfitting

Overfitting pada dataset kecil merupakan risiko yang nyata karena ketidakseimbangan rasio parameter terhadap data. Eksperimen ini tidak menunjukkan overfitting dalam 2 epoch pelatihan: kedua loss menurun secara konsisten dan gap mengecil. Kondisi ini bukan semata-mata karena ukuran dataset, melainkan karena kombinasi lima mekanisme pencegahan yang berjalan secara bersamaan. Model justru masih berada dalam kondisi underfitting dengan perplexity sekitar 15, yang berarti masih terdapat ruang perbaikan yang signifikan melalui penambahan data, epoch, dan peningkatan rank LoRA.

Nama	Harum Ima Mahadma
NIM	25/569053/PPA/07158
Mata Kuliah	PBAL